

PRO BUSINESS CENTER

AI ENGINEER — ПОЕТАПНЕ ТЕСТОВЕ ЗАВДАННЯ · КРОК 2

Документ 1. Як було прочитано та розпаковано завдання

Розбір вхідних вимог до початку розробки: що саме ми зрозуміли, як декомпозиували задачу і на яких розвилках свідомо обрали один варіант із кількох.

ЩО ПРОСИЛИ — У НАШОМУ ФОРМУЛЮВАННІ

Backend-сервіс, у якому користувач веде **кілька незалежних чат-сесій** з LLM. Сервіс зобов'язаний: пам'ятати історію діалогу, зберігати її у БД, і показувати використання токенів та накопичену вартість **на рівні сесії**. Від нас на цьому кроці — план, не код; критерій — ясність і достатність.

ДЕВ'ЯТЬ ВИМОГ, ВИТЯГНУТИХ ІЗ ТЕКСТУ

Вимога	Як ми її прочитали
Сутності й поля	Мінімум дві: сесія та повідомлення. Розділити, бо читаються різними запитами з різною частотою.
REST endpoints	Три названі явно (створити / надіслати / історія) + два очевидно потрібні: список і видалення.
Контекст історії	«Як нове повідомлення <i>отримуватиме</i> контекст» — питання про стратегію, а не про факт. Отже, очікують компроміс і його обґрунтування.
Usage і вартість	«Де і як» — два різні питання: місце зберігання та момент розрахунку.
Model-specific pricing	Формулювання «щоб формула не була хаотично зашита у route» — це вже підказка очікуваної відповіді: винести в окремий модуль.
Обробка помилок	Чотири названі сценарії трактуємо як мінімум, а не вичерпний список.
Модулі й сервіси	Перевіряють межі відповідальності та тестованість, а не кількість файлів.
Припущення	Явно просять зафіксувати — отже, мовчазні допущення вважаються дефектом плану.
Дедлайн, ETA, ризики	Окремий блок наприкінці; ризики просять назвати «зараз», до реалізації.

ЧОТИРИ РОЗВИЛКИ, ДЕ МИ ОБРАЛИ СВІДОМО

- **Пласкі чи вкладені маршрути?** Обрали вкладені (`/sessions/:id/messages`): приналежність перевіряється одним middleware, «сирітське» повідомлення стає неможливим за конструкцією.
- **Уся історія чи вікно?** Обрали ковзне вікно останніх 20 реплік: вартість розмови інакше росте квадратично від її довжини.
- **Вартість — рахувати чи зберігати?** І те, й інше: лічильник у сесії для швидкого списку, порядкові записи як джерело правди. Рівність між ними закріпили тестом.
- **Чужа сесія — 403 чи 404?** Обрали 404: код 403 підтвердив би сторонній особі, що такий ідентифікатор існує.

Ключове рішення, що визначило решту. Виклик моделі не вшивається в маршрути, а передається як залежність. Це водночас закриває три вимоги завдання: дає межу модуля, робить усю HTTP-поведінку тестованою без мережі й ключа, і робить заміну провайдера правкою однієї точки збірки.

ЩО СВІДОМО ВИНЕСЕНО ЗА МЕЖИ КРОКУ

Стрімінг відповіді (змінює контракт API — винесено в питання), квоти й ліміти, підсумовування витісненого контексту, черга з backoff. Кожне з них зафіксоване як питання або ризик, а не пропущене мовчки.

Деменко Денис

Кандидат на посаду інженера AI

Крок 2 · Документ 1 з 2
Час виконання: **30 хвилин**